

Metody Probabilistyczne i Statystyka

Sprawozdanie Homework 4

Anna Grelewska

Zadanie 1

	n	Markov	$P(X \geq 1.2E(X))$	Chebyshev	$P(X \geq 1.2E(X))$	Exact	$P(X \geq 1.2E(X))$	Markov	$P(X - E(X) \geq 0.1E(X))$	Chebyshev	$P(X - E(X) \geq 0.1E(X))$	Exact	$P(X - E(X) \geq 0.1E(X))$
0	100		0.8333333333		0.2500000000		0.0284439668		0.9090909091		1.0000000000		0.3682016173
1	1000		0.8333333333		0.0250000000		0.0000000001		0.9090909091		0.1000000000		0.0017305361
2	10000		0.8333333333		0.0025000000		0.0000000000		0.9090909091		0.0100000000		0.0000000000

Wnioski:

Tabela przedstawia wyniki dla różnych wartości n (100, 1000, 10000) i pozwala porównać oszacowania nierówności Markowa i Czebyszewa z dokładnymi wartościami prawdopodobieństwa.

Nierówność Markowa

- Bardzo słabe oszacowania, znacznie zawyża prawdopodobieństwo.
- Stałe wartości (0.833333 i 0.909091) niezależnie od n .
- Najgorsza metoda spośród analizowanych.






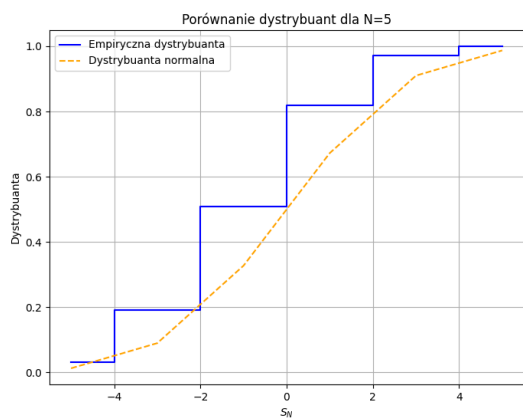
Nierówność Czebyszewa


- Lepsza od Markowa, ale nadal przeszacowuje rzeczywiste wartości.
- Maleje wraz ze wzrostem n , co czyni ją bardziej dokładną dla dużych próbek.
- Dla dużych n jest bliżej rzeczywistych wartości.

Dokładne wartości prawdopodobieństwa

- Są znacznie mniejsze niż oszacowania Markowa i Czebyszewa.
- Dla dużych n szybko dążą do 0, co pokazuje, jak konserwatywne są te nierówności.
- Czebyszew jest dokładniejszy niż Markow, ale nadal znacznie zawyża wartości.
- Dokładne wartości są znacznie niższe, co pokazuje, że nierówności te dają bardzo luźne ograniczenia.

Zadanie 2





Wnioski:




Dla małych N (np. 5, 10) empiryczna dystrybuanta jest silnie skokowa, co wynika z dyskretnego charakteru procesu. Wartości zmiennej losowej S_N przyjmują tylko określone liczby całkowite, co powoduje widoczne "stopnie" w dystrybuancie. Rozkład normalny nie pasuje jeszcze dobrze, ponieważ rozkład S_N jest daleki od ciągłości. Dla większych N (np. 15, 20, 25, 30) empiryczna dystrybuanta staje się bardziej płynna, a skoki są coraz mniejsze. To efekt zwiększającej się liczby możliwych wartości S_N , co zmniejsza różnice między kolejnymi poziomami. Aproksymacja normalna zaczyna lepiej pasować do danych. Dla $N = 100$ empiryczna dystrybuanta niemal całkowicie pokrywa się z dystrybuantą normalną. Skoki są praktycznie niewidoczne, a dystrybuanta przyjmuje niemal ciągły charakter.

Błądzenie losowe dla dużego N jest bardzo dobrze aproksymowane przez rozkład normalny, co jest zgodne z Centralnym Twierdzeniem Granicznym. Dla małych wartości N , proces pozostaje wyraźnie dyskretny, przez co rozkład normalny nie jest jeszcze dokładnym modelem.

Dla $N = 100$ suma kroków losowych zachowuje się niemal jak zmienna o rozkładzie normalnym $N(0, N)$, co oznacza, że wartości empiryczne są praktycznie zgodne z wartościami teoretycznymi wynikającymi z rozkładu normalnego.

Wyniki pokazują, że wraz ze wzrostem N dystrybuanta empiryczna coraz lepiej dopasowuje się do rozkładu normalnego. Dla dużych wartości N błądzenie losowe można skutecznie przybliżyć rozkładem Gaussa, co potwierdza teoretyczne przewidywania.

Zadanie 3



Wnioski:

Dla $N = 100$ histogram jest nieregularny, ale widoczna jest tendencja do większej liczby wartości blisko 0 i 1.

Dla $N = 1000$ kształt histogramu coraz lepiej pasuje do rozkładu arcus sinus.

Dla $N = 10000$ histogram niemal idealnie pokrywa się z funkcją gęstości arcus sinus.

Empiryczna gęstość P_N dobrze aproksymuje rozkład arcus sinus, zwłaszcza dla dużych N . Najwięcej wartości P_N znajduje się blisko 0 i 1, co oznacza, że błądzenie często przebywa nad lub pod osią OX przez długi czas.

Średnia $E(P_N) \approx 0.5$, a wariancja maleje wraz ze wzrostem N .

Dla dużych wartości N rozkład P_N jest zgodny z przewidywaniami teoretycznymi.